データ分析: OLS 入門

川田恵介

2026-04-19

Table of contents

第 1 章　はじめに 7

第 2 章　データの要約 9

2.1　分布による要約 9

2.1.1　分布の限界 11

2.2　平均値による要約 12

2.2.1　平均値の限界 12

2.3　条件付き平均値による要約 13

2.3.1　条件付き平均値の限界 15

2.4　線型モデルへの要約 15

2.4.1　OLS 15

2.4.2　モデルの定式化 16

2.4.3　OLS の計算方法 17

2.4.4　線型モデルの限界 18

2.5　モデルの複雑化 19

第 3 章　母集団の要約と推定 25

3.1　推定問題の枠組み 26

3.1.1　頻度論 26

3.1.2　推定結果と推定目標 27

3.2　母集団とサンプルリング 27

3.2.1　母集団 27

3.2.2　推定目標の定義 28

3.2.3　抽出 29

3.2.4　推定結果と推定方法 30

3.2.5　まとめ 30

3.3　推定方法 32

3.3.1　一致性の限界 33

3.4　信頼区間 34

3.4.1　統計的推論 34

3.4.2　信頼区間 34

3.4.3　信頼区間の解釈 36

3.5　複雑すぎるモデルの問題点 38

第 4 章　研究目標への接続 43

4.1　論点整理 43

4.1.1　3 層構造 43

4.2　変数の関連性把握 46

4.2.1　OLS の注意点 47

4.3 予測 48
4.3.1 OLS の注意点 51
4.4 比較 52
4.4.1 調整後の比較 53
4.4.2 OLS の注意点 54
4.5 因果効果 55
4.5.1 OLS の注意点 57
4.6 まとめ 58

第 1 章

はじめに

本ページでは、データ分析における基本的な手法の一つである「母平均」および「Population OLS」の推定方法について、その基本概念とともに紹介します。

特に、「推定対象として定義された母集団上での計算と同じ操作を、実際のデータ上で行う」というシンプルかつ応用の範囲が広い推定の考え方に注目します。このアプローチは、モーメント法 (Method of Moments)[*1]として知られており、より一般的な推定方法の一例としても位置づけられます。

なお、本ページのメインの議論は、「研究者が定式化」したモデルを**どのように計算・推定するのか**、に関するものであり、**どのようなモデルを定式化すべきか**については扱いません。あるべき定式化については、最終章で代表的な議論を簡単に紹介します。

より詳しく学びたい方には、以下の教科書を推奨します。

- Applied Causal Inference Powered by ML and AI: 以下の公式ホームページから、無料で入手できる。本ページの内容は、主に 1 章と対応します
  - homepage
- Aronow and Miller (2019)：有料だが、Applied Causal Inference Powered by ML and AI より少ない前提知識で読める

[*1] より一般的には、プラグイン原理（plug-in principle）や アナログ原理（analogy principle）

第 2 章

データの要約

データ分析において、結果を人間が理解できる形で要約することは不可欠です。これは、分析結果は予測や推薦、社会構造に関する示唆など多様な形で提示されますが、最終的には意思決定者が理解できる形式で示す必要があるためです。

❗ 到達目標

- データの要約が必要な理由の理解
- 「条件付き分布 → 条件付き平均値 → 線型モデル」の順番で、変数間の関係性が要約できることの理解

2.1 分布による要約

具体的な例を示すために、まず `AER` package から `CPSSW04` データを読み込み、一部の事例を表示します。

Table2.1

```
library(tidyverse) # tidyverse パッケージの読み込み

data("CPSSW04", package = "AER") # データの読み込み

head(CPSSW04) # 一部の事例の抜き出し
```

```
  earnings     degree gender age
1 34.61538   bachelor   male  30
2 19.23077   bachelor female  30
3 13.73626 highschool female  30
4 19.23077   bachelor female  30
5 19.23077   bachelor   male  25
6 38.46154   bachelor female  32
```

CPSSW04 はアメリカの労働者についての調査であり、四つの変数 (所得: earnings, 学位: degree, 性別: gender, 年齢: age) が観察できます。また合計で 7986 事例が含まれています。

このような巨大なデータを直接理解できる人間は、存在しないでしょう。

そこで、最も基本的な要約方法は分布表を作成してみます。分布とは、変数の値が同一である事例数を示します。例えば、count 関数を用いると、学位と性別の分布は次のように計算できます。

```
count(
  CPSSW04,
  degree,
  gender)
```

```
      degree gender    n
1 highschool   male 2772
```

```
2 highschool female 1574
3   bachelor   male 1901
4   bachelor female 1739
```

n に事例数が表示されています。例えば、男性で高校卒の事例は 2,772 件存在することがわかります。

割合を加えることで、データ全体に占める比率も把握できます。

```
      degree gender    n      割合
1 highschool   male 2772 0.3471074
2 highschool female 1574 0.1970949
3   bachelor   male 1901 0.2380416
4   bachelor female 1739 0.2177561
```

CPSSW04 において、全体の 1/3 程度が高校卒の男性であることなどがわかります。

2.1.1　分布の限界

CPSSW04 には、earnings や age などの連続変数も含まれています。これらは CPSSW04 データの特徴を理解する上で、非常に重要な変数でしょう。しかしながら複数の連続変数を含めると、分布表は巨大になり、理解が困難です。

例えば、earnings, age, degree, gender について、度数分布表を作成すると、4,649 行の表が作成されます。このような巨大な分布表の理解は、非常に困難です。

なお少数の連続変数の分布に注目するのであれば、ヒストグラムなどの分布を可視化するツール (Data visualization) を利用することで、人間が認識しやすくできます。しかしながら複数の変数の分布を可視化することは、困難です。

2.2　平均値による要約

分布全体の特徴ではなく、個別の変数の特徴を把握する方法も数多く提案されています。中でも各変数の分布を、その特徴を表す統計量 (statistics) に要約する方法が有力です。

最も代表的なものは、平均値です。例えば `earnings` の平均値 (平均所得) は、以下の方法で計算結果として定義できます。

$$\text{平均所得} = \frac{\text{第1事例の所得} + \text{第2事例の所得} + \ldots}{\text{事例数}}$$

平均値は、**分布のみ**を用いて計算することも可能です。

$$\begin{aligned}\text{平均所得} &= 1 \times \text{「所得が1」の割合} \\ &+2 \times \text{「所得が2」の割合}\end{aligned} \tag{2.1}$$

無論、どちらの方法でも同じ値が計算されます。

`CPSSW04` に含まれるすべての変数について、`summary` 関数は、他の統計量とともに、平均値を計算します。

`Mean` に表示される数値が平均値です。例えば、`CPSSW04` データにおける平均年齢は 29.75 才です。

2.2.1　平均値の限界

平均値には、変数間の関係性を示さないという問題があります。例えば、Table 2.2 を見ても、`earnings` と `age`,`degree`,`gender` の間の関係性について、何もわからないでしょう。

変数間の関係性を把握する方法には、数多くの提案があります。ここでは条件付き母平均、および線型モデルを用いる方法を紹介します。

Table2.2

```r
summary(CPSSW04)
```

```
    earnings             degree        gender          age
 Min.   : 2.098   highschool:4346   male  :4673   Min.   :25.00
 1st Qu.:10.684   bachelor  :3640   female:3313   1st Qu.:27.00
 Median :14.904                                   Median :30.00
 Mean   :16.771                                   Mean   :29.75
 3rd Qu.:20.292                                   3rd Qu.:32.00
 Max.   :61.058                                   Max.   :34.00
```

2.3　条件付き平均値による要約

もし少数の目的変数と多数の説明変数の関係性を把握することが目標であれば、**条件付き分布**から計算できる**条件付き平均値**の利用が有効です。

条件付き分布は、ある特定の条件を満たす事例内での分布です。例えば、「大学卒内での earnings $= 1$ の割合」は以下で計算できます。

$$\text{大学卒内での「所得が1」の事例割合}$$
$$= \frac{\text{大学卒かつ「所得が1」の事例割合}}{\text{大学卒の事例割合}}$$

条件付き平均値は、ある特定の条件を満たす事例内での平均値です。例えば、大学卒という条件を満たす平均年齢は以下のように計算できます。

$$\text{大学卒の平均所得}$$
$$= 1 \times \text{大学卒内での「所得が1」の割合}$$
$$+2 \times \text{大学卒内での「所得が2」の割合} + \ldots$$

例えば、特定の年齢ごとに条件付き平均賃金を示してみます。

```
ggplot(
  CPSSW04,
  aes(
    x = age,
    y = earnings
  )
) +
  stat_summary(
    geom = "point"
  )
```

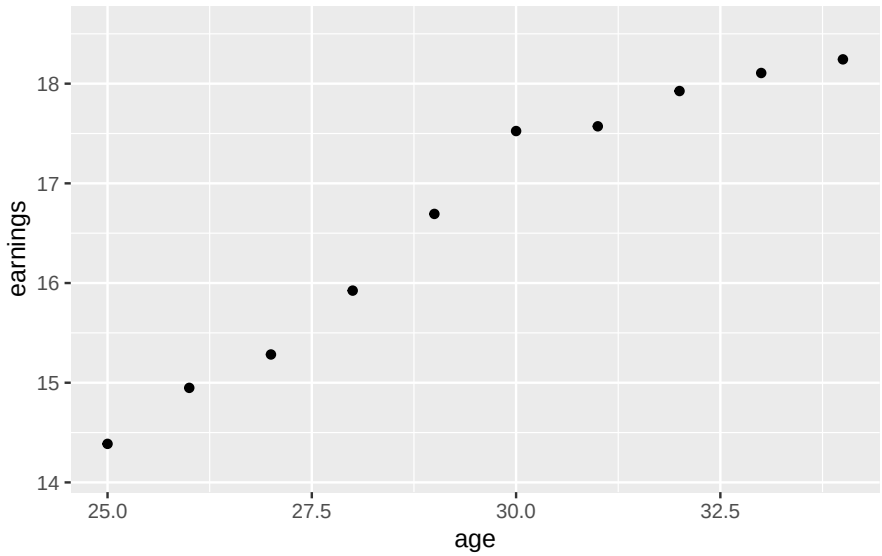

横軸は年齢、縦軸は平均所得、各点が年齢ごとの条件付き平均賃金を表します。同図からは、年齢が上がれば、平均所得も上昇する傾向があることがわかります。

2.3.1　条件付き平均値の限界

説明変数の数が多い場合、大量の条件付き平均値の数が計算されてしまい、理解が困難になります。例えば、年齢・性別・学位について平均賃金を計算した場合、40 個の組み合わせが発生します。データの事例数に比べれば、かなり少なくはなりますが、それでも理解には時間がかかるでしょう。

2.4　線型モデルへの要約

大量の変数間の関係性を要約するために、線形モデルを適用する方法が広く用いられます。例えば、賃金と年齢・学位・性別の関係を次のモデルで表すことを目指します。

$$\beta_0 + \beta_1 \times age + \beta_2 \times degree + \beta_3 \times gender \tag{2.2}$$

ただし `degree` と `gender` の値は、数字ではなく、文字です。線型モデルに導入する際には、何らかの数字に変換する必要があります。

ここでは `bachelor` と `gender` をダミー変数、`degreebachelor` と `genderfemale`、に変換します。ダミー変数は、以下のように定義されます。

- `degreebachelor`: `degree` が `bachelor` だった場合は 1、その他の場合は 0
- `genderfemale`: `gender` が `female` だった場合は 1、その他の場合は 0

$\beta_0, \beta_1, \beta_2, \beta_3$ は係数と呼ばれ、モデルがデータに極力一致するように選ばれます。このようにデータに合うように設定したモデルの特徴を調べることで、データの特徴を大雑把に理解することができます。

2.4.1　OLS

モデルをデータに適合される典型的な方法は OLS (最小二乗法) です。具体的な計算方法を紹介する前に、R での実行方法から紹介します。R では、`lm` 関数を用いることで、OLS

Table2.3

```
lm(earnings ~ age + degree + gender, CPSSW04)
```

```
Call:
lm(formula = earnings ~ age + degree + gender, data = CPSSW04)

Coefficients:
   (Intercept)             age  degreebachelor    genderfemale
        1.8838          0.4392          6.8651         -3.1579
```

を容易に実行できます。例えば、以下のコードで、Equation 2.2 を CPSSW04 に適合させることができます。

各説明変数名の下の数値が、係数の計算結果です。Equation 2.2 のようなシンプルな線型モデルにおいて、係数は各説明変数と結果変数である earnings の「モデル上での関係性」を表します。推定結果から、年齢や大学卒は賃金と正の関係があり、男性に比べて女性の賃金が低い傾向にあることがわかります。

2.4.2　モデルの定式化

線型モデルに要約することで、変数間の関係性を「ざっくり」把握することができます。注意が必要なのは、以上の方法では、どのようなモデルをデータに適合させるのかは、分析者が決定する必要がある点です。

どのようなモデルが適しているのかは、研究目標により異なります。「人間がデータの大雑把な特徴を理解する」ことを目標にするのであれば、Equation 2.2 のような、シンプルなモデルが有力です。このような大雑把な理解を目標に設定されたモデルは、**記述モデル**と呼ばれます[*1]。

[*1] データ分析では、記述を目的としないモデルの推定を目指すことがあります。例えば結果変数の値の予測

2.4.3　OLS の計算方法

OLS の具体的な計算方法を紹介します。基本的なアイディアは、データとモデルの乖離度合いを測定する指標である、**平均二乗誤差**を極力小さくするように係数を算出するというものです。

例えば、`age` のみを説明変数として、`earnings` について、以下の線形モデルを設定します。

$$\beta_0 + \beta_1 \times age$$

ある事例 i についての二乗誤差は以下のように定義されます。

$$\text{事例}i\text{の二乗誤差} = (\text{事例}i\text{の所得} - \underbrace{(\beta_0 + \beta_1 \times \text{事例}i\text{の}age)}_{\text{モデルが算出する賃金}})^2$$

OLS は全ての事例について、二乗誤差の平均値 (平均二乗誤差) を最小にするように係数を算出します。

平均値と同様に、OLS も別の計算方法があります。この方法は、分布と条件付き平均値のみを用いて計算できます。以下の条件付き平均値についての二乗誤差を最小化するように係数の値を算出します。

$$\begin{gathered}(\text{25才の平均所得} - (\beta_0 + \beta_1 \times 25))^2 \times \text{25才の割合} \\ +(\text{26才の平均所得} - (\beta_0 + \beta_1 \times 26))^2 \times \text{26才の割合} \\ +...\end{gathered}$$

こちらの計算方法では、係数を「モデルが条件付き平均値に極力適合するように決定」するので、算出されたモデルは条件付き母平均のモデルであると解釈できます。この解釈は、社会データの分析において現実的であり、多くの教科書で採用されています (Angrist and Pischke 2009; Aronow and Miller 2019; Chernozhukov et al. 2025)。

を目指すモデルは、予測モデルと呼ばれます。予想モデルについては、分析者がモデルの詳細な構造を理解することを**主たる目的としないため**、より複雑なモデルが設定されます。

2.4.4　線型モデルの限界

線型モデルは、あくまで関係性を単純化するため、実際の条件付き平均値を完全には反映しません。

例えば earnings について、

$$\beta_0 + \beta_1 \times age$$

を OLS で当てはめてみます。実際の条件付き平均値とモデルの関係性は、以下でした。

```
CPSSW04 |>
  ggplot(
    aes(
      x = age,
      y = earnings
    )
  ) +
  stat_summary(
    aes(
      color = "条件付き平均値"
    ),
    geom = "point"
  ) +
  geom_smooth(
    aes(
      color = "モデル"
    ),
    method = "lm",
    se = FALSE
  )
```

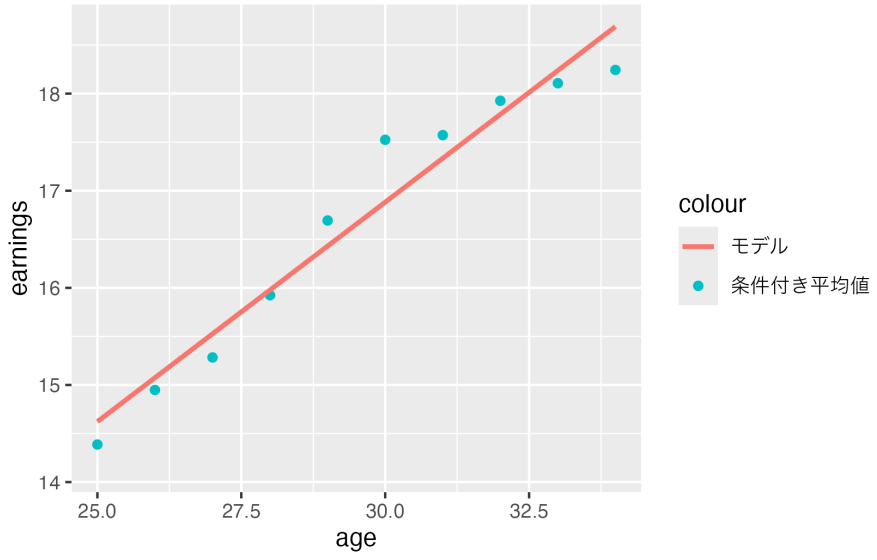

Figure2.1

各点は年齢ごとの条件付き平均値、直線が OLS で推定された線型モデルとなります。

線形モデルは、平均賃金と年齢が概ね右上がりの関係 (高年齢は賃金が高い) を捉えることができています。ただし実際の平均賃金と年齢の関係性は、モデルのように" 一直線" ではありません。線形モデルは、この特徴を捉えることには失敗しています。

2.5　モデルの複雑化

データ上の平均値とモデルの乖離は、推定するモデルを複雑化することで、簡単に削減できます。例えば以下のモデルを、OLS でデータに当てはめてみます。

$$\beta_0 + \beta_1 \times age + \beta_2 \times age^2$$

$\beta_2 \times age^2$ は高次項と呼ばれます。このような項を加えても、OLS を用いればパラメータ

の推定は可能です。

下図は、この 2 次モデルをデータに当てはめた結果を示しています。直線ではなく、年齢に対して曲線的な関係が推定されており、データ上の条件付き平均値により近づいていることがわかります。

```
CPSSW04 |>
  ggplot(
    aes(
      x = age,
      y = earnings
    )
  ) +
  stat_summary(
    aes(
      color = "条件付き平均値"
    ),
    geom = "point"
  ) +
  geom_smooth(
    aes(
      color = "モデル"
    ),
    method = "lm",
    se = FALSE,
    formula = y ~ poly(x,2)
  )
```

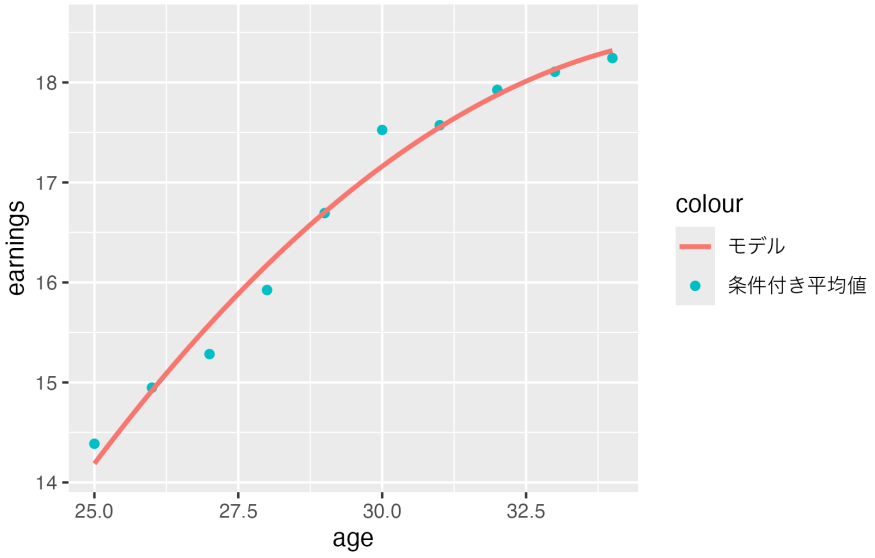

では、さらにモデルを複雑にするとどうなるでしょうか？ 次に、9 次までの高次項を含む以下のモデルを考えてみます。

$$\beta_0 + \beta_1 \times age + .. + \beta_9 \times age^9$$

このような高次の多項式モデルを用いると、モデルの予測値はデータ上の平均値とほぼ完全に一致するようになります。

```
CPSSW04 |>
  ggplot(
    aes(
      x = age,
      y = earnings
    )
  ) +
```

```
stat_summary(
  aes(
    color = "条件付き平均値"
  ),
  geom = "point"
) +
geom_smooth(
  aes(
    color = "モデル"
  ),
  method = "lm",
  se = FALSE,
  formula = y ~ poly(x,9)
)
```

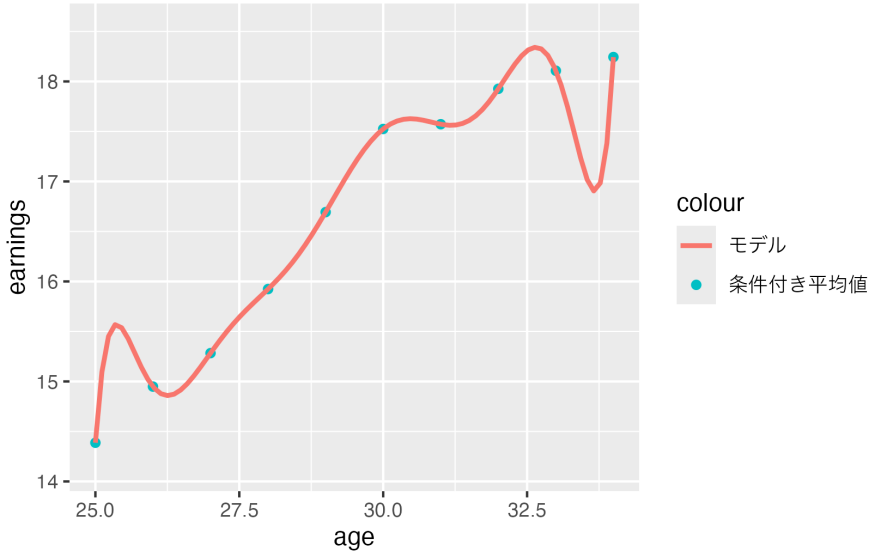

このように、線形回帰モデルは非常に柔軟な枠組みであり、どれほど複雑な形であっても、モデルが"β の足し算" である限り、データに当てはめること自体は可能です。

複雑なモデルには、以下のような魅力があります。

- データとの適合度が非常に高い
- 現実の社会や市場は複雑であるため、モデルも複雑な方が良いと感じられる

しかしながら、複雑すぎるモデルにはいくつかの問題点があります。

- 過学習（オーバーフィッティング）により、モデルの推定精度が悪化する（詳しくは Section 3.5 を参照）
- モデルの構造が複雑すぎると、人間がその意味を理解しにくくなる（詳しくは Chapter 4 を参照）

そのため、モデルの複雑さは、データの量や研究目標に応じて慎重に調整する必要があります。具体的な研究目標とそれに応じた OLS の活用方法は、Chapter 4 で紹介します。

第 3 章

母集団の要約と推定

平均値や OLS の結果は、計算に用いるデータによって異なります。例えば、1947 年に実施された第 1 回目の労働力調査と 2025 年に行われた調査では、平均賃金が大きく異なるでしょう。これは 1947 年と 2025 年では、社会状況が大きく異なるので、当然の結果と考えられます。

では全く同じ社会を対象とした調査を、複数の研究チームが行った場合に、同じ平均賃金が算出されるでしょうか？ もし同じ結果が得られないのでは、分析結果には、「客観性がなく信用できない」とも考えられます。このような場合、分析結果をどのように受け取れば良いでしょうか？

以上の問題は、推定問題と呼ばれ、データ分析における中心的な課題の一つです。

❗ 到達目標

- 推定対象と推定結果を明確に区別する
  - 推定対象と推定結果を定義するための概念: 母集団と抽出を理解する
- 推定対象を推論するツール、信頼区間を理解する

3.1　推定問題の枠組み

3.1.1　頻度論

推定問題を考える土台となる枠組みとしては、頻度論とベイズ論が有名です。本ページでは、頻度論に基づく議論を紹介します。

まずは、以下の**思考実験**を考えてください。

> ❗ Important 1: 思考実験
>
> 日本全国に、「2025 年の日本の労働市場」を分析する研究チームが、大量に組織されました。各チームは同じ手順に基づき、平均賃金を計算します。ただしデータの収集は、各チームが**独立**して行います。
> **果たして、各チームは同じ結論にたどり着くでしょうか？**

もし全てのチームが同じデータと同じコードを使えば、コーディング・ミスなどがない限り同じ結果になるはずです。ところが、各チームが電話・ネット調査などでそれぞれが独自にデータを集めた場合、調査対象の対象となった回答者の違いから、得られるデータが異なり、結果も変わる可能性があります。

この思考実験の結果は、Chapter 2 で紹介した手法等を用いた推定結果の信頼性を「“否定” します」。なぜならば、目の前にある推定結果は「誰にも再現できず」、この結果を信じる「合理的な根拠」がないためです。

この再現をめぐる問題について、「じゃんけん」を比喩として使ってさらに考えてみます。

> ❗ じゃんけんの比喩
>
> いま、「1 度じゃんけん勝負を行い勝った」とします。この結果を根拠に、「自分は永遠に勝ち続ける」と結論づけることは妥当でしょうか？
> 大部分の人は、「負けることもあり得た中で、偶然勝っただけであり、もう一度や

ると結果が変わりそう」(結果を再現できないのではないか) と「想像」し、このような極端な結論を否定するのではないでしょうか？
データ分析についても同様であり、「同じ社会について、さまざまなデータが収集されうる中で、偶然手にしたデータから得られた推定結果であり、もう一度データを取り直すと結果が変わりそう」と考え、本章で紹介する信頼区間などを活用します。
言い換えると、Chapter 2 のようなデータから得られた (再現できない) 計算結果を、「一般性のある結論」と見做すと、「じゃんけんに一回勝ったから、永遠に勝ち続けられると思いこむ」ことと同様の誤りを犯すことになります。

3.1.2　推定結果と推定目標

この思考実験の (ネガティブな) 結果への対応策を議論するために、いくつかの理論的な概念が導入されます。

このような概念の中でも、特に次の 2 つを区別することが重要です:

- **推定結果**（estimate）：データから実際に計算される値
- **推定目標**（parameter of interest/estimand）：推定の対象となる “真の値”

たとえば、`CPSSW04` データから計算される平均所得は、あくまで「推定結果」であり、「全米の平均所得」という推定目標に近づくことを期待して計算されます。

推定結果と推定目標の関係性を明確にするために、**母集団**と**抽出**という概念を導入します。

3.2　母集団とサンプルリング

3.2.1　母集団

母集団 (Population) とは、推定の対象となる集団のことです。Important 1 における母集団は「2025 年の全世帯」、`CPSSW04` では、「2004 年のアメリカの全世帯」が妥当な母集

団でしょう。

3.2.1.1　母分布

母分布は、母集団における変数の分布です。本ページでは、データに含まれる変数について、母集団全員を調査し、計算された分布であるとイメージしてください。

例えば CPSSW04 の母集団である 2004 年のアメリカの全世帯が観察できれば、同年の特定の [収入、学位、性別、年齢] が、全人口に占める割合が計算できるはずです。

以下では、「分析者は母集団を直接観察できず、**母分布を実際に計算することは不可能である**」、という状況を想定します。そして、直接知ることができない母分布やその特徴を、データから推定することを試みます。

3.2.2　推定目標の定義

本ページでは、母分布そのものではなく、母分布の特徴を推定する方法を紹介します。推定の対象となる母分布の特徴を、推定目標と呼びます。代表的なものとしては、母分布から計算された**平均値**および **OLS の結果**があります。

3.2.2.1　母平均

データにおける分布と同様に、母分布からも平均値や条件付き平均値を計算できます。このような母集団における平均値を、母平均と呼びます。

例えば、母集団における 25 才の平均所得は以下のように計算できます。

$$
\begin{aligned}
&25\text{才の条件付き母平均}\\
&= 1 \times 25\text{才における「}earnings\text{が}1\text{」の条件付き母分布}\\
&+2 \times 25\text{才における「}earnings\text{が}2\text{」の条件付き母分布}\\
&+\ldots
\end{aligned}
$$

3.2.2.2　Population OLS

本スライドでは、母分布から計算される OLS の結果を推定目標とします。このような推定目標を母集団における OLS 推定値 (Population OLS) と呼びます。

例えば、賃金と年齢の関係性を捉えるために、以下の母集団における平均二乗誤差を最小化する線型モデル ($\beta_0 + \beta_1 \times age$) を Population OLS として定義できます

$$
\begin{gathered}
(25\text{才の母平均} - (\beta_0 + \beta_1 \times 25))^2 \times 25\text{才の母分布} \\
+(26\text{才の母平均} - (\beta_0 + \beta_1 \times 26))^2 \times 26\text{才の母分布} \\
+\ldots
\end{gathered}
$$

これらはすべて、実際には観察できない仮想的な計算結果です。この結果をデータから推定することを目指します。

3.2.3　抽出

データは、何らかの方法で選ばれた事例の集まりであると想定します。この事例を選ぶ過程を、**抽出 (sampling)** と呼びます。

母集団について推測するためには、データと母集団の関係について何らかの仮定を置く必要があります。特に、母集団の事例をどれだけ偏りなくサンプリングできているのかは、分析の信頼性に大きく影響します。

最も重要な仮定は、ランダムサンプリングです。

> ❗ Important 2: ランダムサンプルングの仮定
>
> - データの各事例は、母集団から個別にランダムに選ばれている

本ページでは、分析に用いるデータはランダムサンプルングを満たすことを想定します。

3.2.4　推定結果と推定方法

推定結果（estimate）とは、データから計算される値のことです。この推定結果は、推定対象（母集団上での真の値）に近い値であることが期待されます。

推定結果を計算する手順のことを、**推定方法（estimator）**と呼びます。

3.2.5　まとめ

本節で登場した重要な概念と仮定を整理すると、次のようになります。

❗ 母集団、抽出、推定対象、推定結果

- **母集団**: 推定対象となる集団
  - **推定対象**: 母集団上で行いたい仮想的な計算
- **抽出**: 母集団から事例を収集する手順
  - **ランダムサンプルングの仮定** (Important 2)：事例は、母集団からランダムに選ばれている[*1]
- **データ**: サンプリングされた事例の集団
  - **推定結果**: データから計算される結果 (推定対象に近い値であることが期待される)
  - **推定方法**: データから推定結果を計算する具体的な計算方法

これらの関係は、以下の図にまとめられます：

[*1] 厳密にはデータの事例が独立・無相関に選ばれている (Independent and Identically Distributed) を仮定しています。

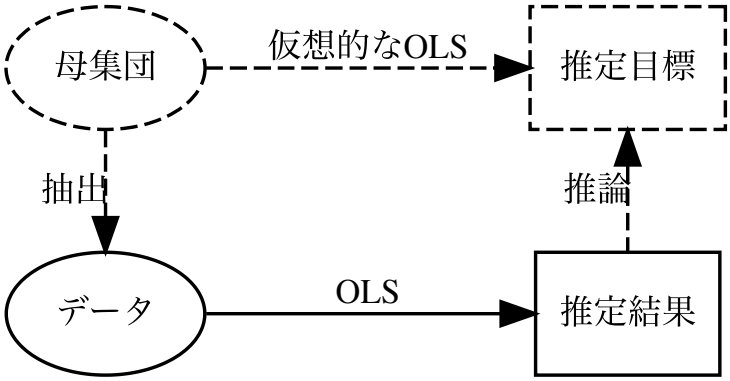
母集団
仮想的なOLS
推定目標
抽出
推論
データ
OLS
推定結果

図中の実線は、データの分析者が実際に観察・操作できる要素を、点線は想像上の操作や概念を表しています。例えば、母集団から推定対象を計算する作業を、分析者が実際に行うことはできません。なぜならば、母集団を直接観察することができないためです。

研究が直接確認できるものは、目の前のデータとそこから計算した推定結果のみです。また研究者が具体的に行うことができる操作も、データを用いた推定結果の計算 (OLS 等) のみです[*2]。

3.3　推定方法

母平均や Population OLS は、以下の一般的な推定方法が利用できます[*3]。

> ❗ Important 3: 母平均や Popualtion OLS の推定
>
> 1. **母集団上での仮想的な計算結果** として、推定対象を定義する
> 2. **同じ計算をデータ上で行った結果**を、推定結果とする

この推定方法は、以下の性質から正当化できます。

> ❗ Important 4: 一致性
>
> もしデータに代表性があり、かつ事例数が無限大であれば、データから算出した OLS の結果と Population OLS は一致する。

一致性からは、データが増えれば増えるほど、推定結果は推定目標に近づくことが期待できます。

ただし、この議論は「母集団において平均値や OLS の結果が計算できる」ということを、前提にしていることに注意してください。例えば、母分布が「特殊な」場合、母平均が無

[*2] 実際のデータ分析では、OLS やベイズ法、機械学習による推定だけでなく、データの前処理も研究者が行うべき重要な操作となります。

[*3] アナログ原理やプラグイン原理として呼ばれています。

限大になり、計算できない場合があります[*4]。また Population OLS については、母集団において完全な多重共線性が存在する場合、計算は不可能です。そのため、多重共線性のない定式化を用いて、Population OLS を定義する必要があります。

3.3.1 一致性の限界

一致性は、推定方法 Important 3 を正当化する重要な性質です。しかしながら、実際のデータ分析においては、それほど実用的な性質ではありません。なぜならば、Population OLS とデータ上での OLS が一致するためには、**無限大の事例数**が必要となるからです。いうまでもなく無限大の事例数を持つデータは存在しません。言い換えると、実際のデータ分析では、推定結果と推定目標は" 乖離している" と想定すべきです。

具体的な例から考えてみます。

```r
library(tidyverse)

data("CPSSW04", package = "AER")

lm(earnings ~ age, CPSSW04)
```

```
Call:
lm(formula = earnings ~ age, data = CPSSW04)

Coefficients:
(Intercept)          age
     3.3242       0.4519
```

以上の結果は、データ上での OLS では、age のパラメタは 0.4519 であることが確認できます。一致性から、もし CPSSW04 がランダムサンプルングの仮定を満たし、事例数が無

[*4] 母平均が計算できないケースとしては、母分布がコーシー分布である場合などが有名です。

限大であれば、「**Population OLS** における age のパラメタも 0.4519 である」という結論は必ず正しいものとなります。ところが実際の事例数は、7986 であり、無限ではありません。このため「**Population OLS** における age のパラメタも 0.4519 である」は、ほぼ間違った結論となります。

! ポイント

ここまでの議論から、Important 1 の思考実験の結果は以下のように整理できます。

- 各研究チームは、ランダムサンプリングにより、データを集めたとする
  - データの事例数が無限大あれば、データから得られる OLS の結果は、常に Population OLS と一致する
    - データから得られる推定結果は、どの研究チームでも同じ
  - 現実的な事例数のもとでは、データから得られる OLS の結果は、常に Population OLS から乖離
    - データから得られる推定結果は、研究チームよって異なる

3.4　信頼区間

3.4.1　統計的推論

「無限大のデータ」という非現実的な想定に頼らずに、正しい結論を示すことは可能でしょうか？ データ分析においては、**確実に**正しい結論を示すことは、事実上不可能です。このため多くのデータ分析では、**ほぼ**正しい結論を示すことを目指します。このような**ほぼ正しい**結論を示すプロセスは、**統計的推論**と呼ばれます。

3.4.2　信頼区間

統計的推論に活用できるツールは、さまざまなものがありますが、中でも信頼区間が代表的です。

❗ 信頼区間

- 推定対象を一定の確率で含むと考えられる区間
  - 推定対象を含む確率は、信頼確率と呼ばれ、研究者が指定する
  - 手元にあるデータから計算される

R において、信頼区間を計算する方法は複数存在します。例えば `estimatr` パッケージの `lm_robust` 関数を用いれば、以下の仮定のもとで、信頼区間を計算します。

❗ 信頼区間計算の前提条件

- データはランダムサンプルングされている
- 事例数は十分にある[*5]
- 極端なハズレ値がない

例えば、以下のコードから、`reform` の平均値について 95 % 信頼区間を計算できます。

[*5] どのくらいあれば十分なのかは、難しい問題です。ただし多くの教科書では、200 事例以上が基準とされています。

Table3.1

```
model <- estimatr::lm_robust(
  earnings ~ age,
  CPSSW04)

model
```

```
             Estimate Std. Error   t value     Pr(>|t|)  CI Lower  CI Upper
(Intercept) 3.3241841  0.9657404  3.442109 5.801562e-
04 1.4310807 5.2172874
age         0.4519313  0.0329688 13.707847 2.737848e-
42 0.3873039 0.5165588
              DF
(Intercept) 7984
age         7984
```

以上の結果から、「Population OLS における age は、概ね (95 %) 0.387 ∼ 0.517 である」という主張を行うことができます。

3.4.3　信頼区間の解釈

本ページでは信頼区間の詳細な導出方法の説明は省略します。代わりに信頼区間の解釈を詳細に紹介します。

95% 信頼区間を活用する際に問題となるのは、95% の意味を正しく捉えることです。そこで本節では、信頼確率について、いくつかの異なる、ただしすべて正当な解釈を紹介します[*6]。

まずは 思考実験 Important 1 と最も密接な解釈である「繰り返し抽出」です。

[*6] Hanley (2025)

解釈 1. 多数の研究チーム

皆さんと他の研究チームは、同じ方法でデータを収集しますが、収集自体は独立して行い、データのシェア等も行いません。このため、データの特徴は全てのチームで異なっており、計算される信頼区間も異なります。
これらの分析チームが各のデータから、95 % 信頼区間を計算したとします。もし信頼区間の仮定が全てのチームで満たされているならば、皆さんを含む大量のチームが計算した信頼区間のうち、95 % は推定対象 (真の値) を含みます。

このような解釈は多くの教科書で紹介される標準的なものですが、歴史的に「わかりにくい」と批判されてきました。特に社会・市場分析において、「同じ母集団を対象に研究する大量の分析チーム」が存在した現実の例を挙げることは困難であり、かなり抽象的な想像力が要求されます。

2 つ目の解釈は「一人の研究者が長期間にわたって大量の研究を行う」という、より現実的な想像を土台に、信頼区間を" 生産物" の品質管理として捉える解釈です。

解釈 2. データ分析についての品質保証

これから皆さんは長期に渡って、さまざまな母集団 (社会) や研究目標について、多くのデータ分析を行なっていくとします。これら全ての分析において、ランダムサンプリング等の仮定が満たされていることを前提に、95 % 信頼区間を計算したとします。当然さまざまな信頼区間が計算されますが、今後皆さんが計算する大量の信頼区間のうち、95 % は推定対象を含むことができます。

このような品質保証のような見方を、信頼区間の提唱者であるネイマンは**帰納的行動** (Inductive Behavior) と呼びました。

最後に信頼区間は、仮説検定というアプローチと密接な関係があります。

解釈 3. 検定の反転

今、ある推定対象 (例えば改装率) について、候補となる値がたくさん存在します。この中から、明らかに推定対象ではないと値を除外していきます。除外する方法は以下です。

1. 仮にある値が推定対象の真の値 (例えば 1 %) だと想定する
2. もしこの仮の値が、データ上での値とあまりにかけ離れている場合は、真の値の候補から除外する (この判断において、統計的検定を活用します)
3. 全ての値について、 1 、 2 を繰り返し、除外されなかった値を信頼区間とする

つまりデータと大きく矛盾しない値の集合を信頼区間とします。

検定の反転を実際に行うためには、統計的検定の知識が必要です。統計的検定については、本ページでは紹介しませんが、標準的な統計学・計量経済学の入門書では必ず紹介されているので、読んでみてください。

以上の解釈は、数学的には実は全て同じものであり、ストーリーが違うだけです。各自が「一番しっくりくるもの」をとりあえずは選んで問題ありません

3.5　複雑すぎるモデルの問題点

モデルが複雑すぎると、推定において深刻な問題が生じることがあります。複雑なモデルのパラメータを高い精度で推定するためには、十分な数の観測事例が必要になるためです。このためデータ数が限られている場合、複雑なモデルを推定すると、推定精度が大幅に低下し、ミスリードな推定結果を導くおそれがあります。

ここでは、単純な数値例を用いてこの問題を確認してみます。

❗ 数値例

以下のような複雑な条件付き母平均を想定します[*7]。

$$E[Y \mid X] = X + 0.1 \times X^2 + 2 \times X^3 + 0.01 \times X^4 + 5 \times X^5$$
$$0.1 \times X^6 + 3 \times X^7 + 0.1 \times X^8 + 0.1 \times X^9 + 0.1 \times X^{10} \tag{3.1}$$

条件付き母平均とこの想定に基づいてランダム・サンプルングされた 50 事例のデータを図示すると、以下のようになります。

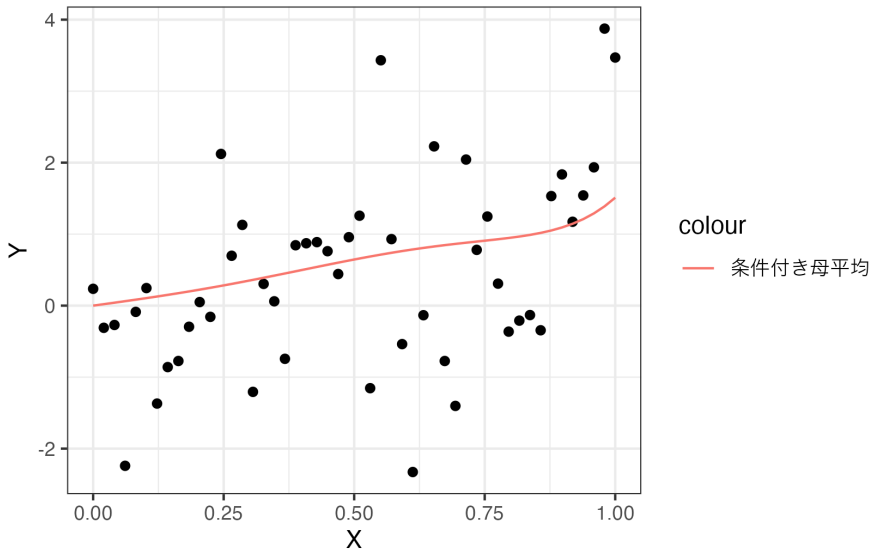

赤線が条件付き母平均、黒点がデータを表します。

まずは、単純な線型モデル $(\beta_0 + \beta_1 \times X)$ を推定し、条件付き母平均を比較してみます。

[*7] 個々の Y と X の値は、以下で決定されます: $X = 0$ から 1 までの一様分布、

$$Y = E[Y \mid X] + \underbrace{u}_{\text{平均0、分散1の正規分布}}$$

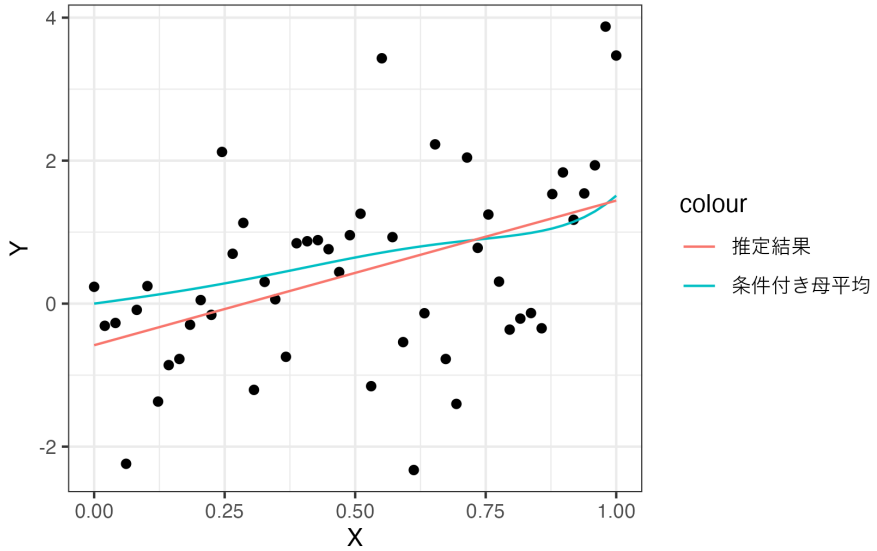

この図からわかるように、単純なモデルでは複雑な母平均を捉えることができず、推定結果と母平均に乖離が生じています。

次に、Equation 3.1 のような複雑な条件付き母平均を想定し、以下のような複雑なモデルを推定し、条件付き母平均を比較します。

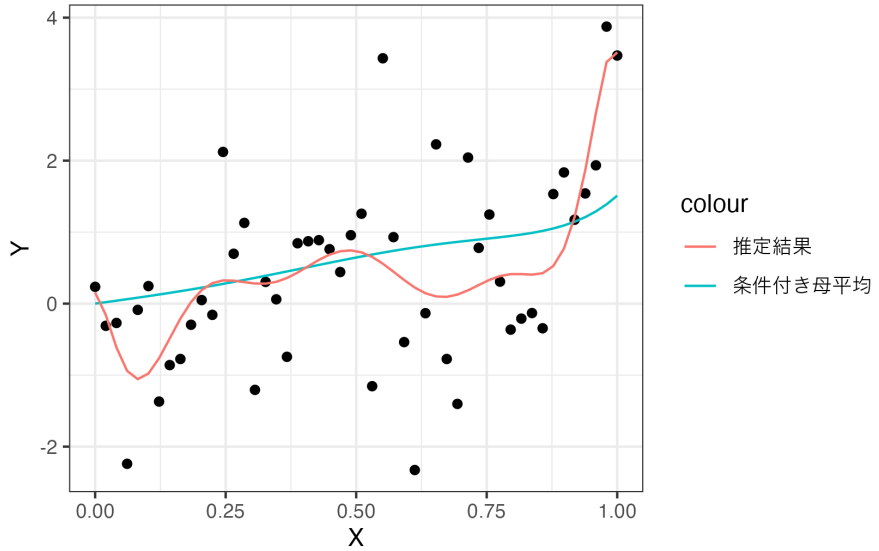

複雑なモデルの方が、条件付き母平均に近づくように思えるかもしれませんが、実際には母平均との乖離がむしろ拡大していることがわかります。これは、少ないデータ（50 事例）で複雑なモデルを推定したため、パラメータの推定精度が著しく低下したことを示しています。

では、同じ複雑なモデルを、十分なデータ（5 万事例）で推定した場合はどうなるでしょうか。

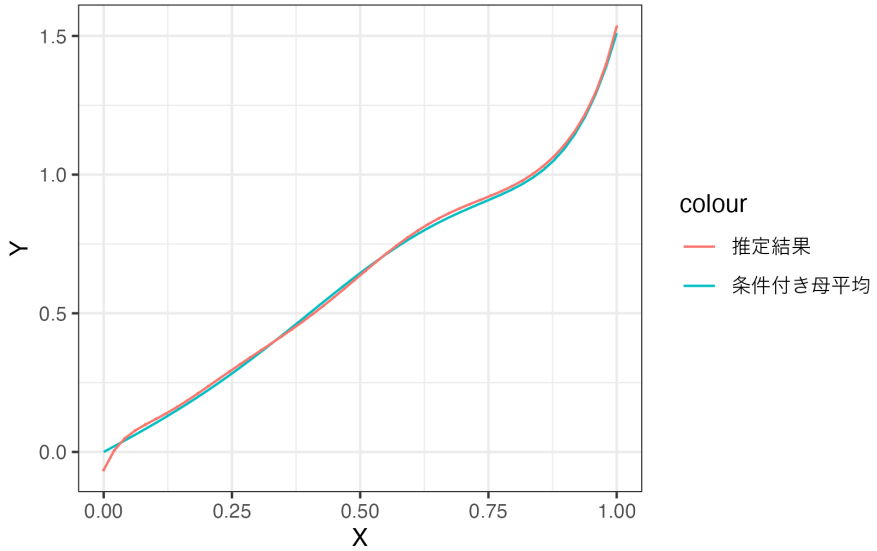

この場合、推定結果は条件付き母平均とほぼ一致しており、十分なデータがあれば、複雑なモデルでも OLS によって高精度な推定が可能であることが確認できます。

この数値例からわかるように、複雑なモデルを用いる際には、十分なデータがあるかどうかを慎重に検討する必要があります。

第 4 章

研究目標への接続

ここまで、あるモデルを**どのように推定するか**を紹介してきました。しかし、**どのようなモデルを推定すべきか**は、研究の目的によって異なります。本章では、望ましいモデルの定式化について、目的別に整理していきます。またそれぞれの研究目的について、OLS を用いる際の注意点と OLS 以外の手法も紹介します。

4.1　論点整理

OLS を有効活用するためには、具体的な研究目標や活用できるデータの性質に合わせて、推定するモデルを適切に定式化する必要があります。また場合によっては、代替的な推定方法 (機械学習、最尤/ベイズ法、マッチング法等) を検討する必要もあります。

データ分析をめぐるこのような判断を行うために、本ページでは二つの枠組みで、論点を整理します。

4.1.1　3 層構造

Chapter 3 では、母集団という概念を導入し、推定目標とデータ、推定結果を紐づけました。推定すべきモデルを考えるためには、ここにさらに研究目標と、その対象となる” 社会” を導入する必要があります。

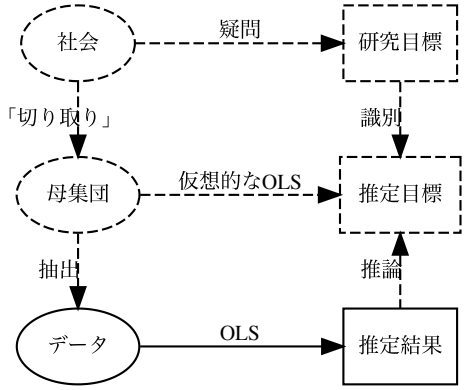

Figure4.1: 3 層構造

経済学において研究目標は、「社会についてのなんらかの**疑問** (Research question) に対する" 回答"」です。ここでいう社会とは、分析の対象となる集団そのもの[*1]を指します。例えば「今日の日本社会における平均教育年数は?」が疑問であれば、その時点での本当の平均教育年数が回答であり、データから推定すべき研究目標となります。

もしこの社会や研究目標が、データから直接回答可能な程度に明確であれば、母集団を導入する理由は特にありません (社会 ≃ 母集団と見なして、大きな実用上の問題は生じません)。

しかしながら実際の社会は、多様な要因が複雑に結びつき、流動的であると考えられます。このような「捉えどころのない社会」についての疑問や研究目標も、必然的に曖昧なものになってしまいます。

実際に「今日の日本社会における平均教育年数は?」という比較的シンプルな研究目標であったとしても、データから正確に回答することは不可能です。なぜならば、社会は日々変化するのに対して、データの母集団は「データを収集した時点で固定」されてしまいます。例えば " すなわちデータやそれに対応する母集団は、社会の一部の表面的な切り取り (スナップショット) に過ぎません。

また複雑な社会を分析するために、経済学や他の社会科学は、大量の概念 (選好、技術、物的/人的/社会的/文化資本、階層、イデオロギー等) を用いてきました。これはあくまでも理論的な概念であり、データから直接観察することは不可能です。このため研究目標に、このような概念が含まれる場合、データから何を推定すべき対象が不明確になってしまいます。

このような曖昧さへの対処として、経済学のデータ分析では、「データから研究目標に答える」という過程を、二つに分割します。

❗ 分析過程の 2 分割

- **推定/推論**: Chapter 3 で議論した「推定目標をデータから推定する」、という過程です。推定目標や母集団は「データからの推定」というタスクに適し

[*1] 予測研究における Target Population (予測したい対象の集団)、伝統的な経済学の実証研究におけるデータ生成過程 (Data Generating Process) などを含む、母集団の" 上位概念" として用いています。

た形で、明確に定義されており、統計学や機械学習の理論を応用することで、このタスクを実行できます。
  - Figure 4.1 における推定目標と推定結果を接続する議論です。
- **識別 (Identification)**: ここまでで議論していない「研究目標と推定目標の対応関係を明らかにする」というタスクです。Section 4.5 で紹介する因果推論や推定結果の外的妥当性を議論する際に非常に重要であり、本章で詳細に議論します。
  - Figure 4.1 における研究目標と推定目標を接続する議論です。

この分割における、推定目標や母集団が果たしている機能に注目してください。わざわざ、母集団というわかりにくいフィクションを導入する意義は、データと研究目標を論理的に接続する" 仮の梯子" の導入であり、複雑な議論をより扱いやすい二つの議論に分割することにあります。

4.2　変数の関連性把握

Chapter 3 のような「シンプルなモデルによる Population OLS」を推定/推論する方法は、「社会における変数間の関係性を簡潔に把握する」という研究目標に直接活用できます。

例えば 2004 年 (`CPSSW04` の調査年) の米国における所得と性別、年齢の関係性を、シンプルな線形モデルで捉え、`CPSSW04` から推定することができます:

$$earnings \simeq \beta_0 + \beta_1 \times gender + \beta_2 \times age$$

Table 4.1 は単純な線形モデルの推定結果であり、ある程度データ分析に慣れていれば、変数間の関係性について容易に示唆を得ることができます。例えば、女性ダミーのパラメタの推定値 (`genderfemale`) は負なので、平均賃金が低い傾向、年齢 (`age`) は正なので、年齢と賃金は正の平均的関係性を持つことが読み取れます。

Table4.1

```r
library(tidyverse)

data("CPSSW04", package = "AER")

estimatr::lm_robust(
  earnings ~ gender + age,
  CPSSW04
)
```

```
               Estimate Std. Error    t value     Pr(>|t|)   CI Lower
(Intercept)   4.6068633 0.96193135   4.789181 1.704803e-06  2.7212266
genderfemale -2.3467550 0.18911541 -12.409116 4.901133e-35 -2.7174706
age           0.4415421 0.03270506  13.500726 4.363752e-41  0.3774316
               CI Upper   DF
(Intercept)   6.4924999 7983
genderfemale -1.9760394 7983
age           0.5056526 7983
```

4.2.1　OLS の注意点

しかし、OLS を用いる際には注意すべき点もあります。特に重要なのは、得られた関係性の要約が、どのようなモデルを推定したのか、すなわちモデルの定式化に大きく依存するという点です。たとえば、どの変数を説明変数として選ぶか、二乗項を加えるかなどの選択によって、分析結果が大きく変わる可能性があります。

また本ページの範囲内では、OLS の推定対象は、あくまで条件付き母平均のモデルであり、母分布そのもののモデルではないことに注意が必要です。もし母分布のモデルを推定する場合は、最尤推定やベイズ推定法が活用されます。

4.3　予測

予測研究とは、推定されたモデルを用いて、目的変数 Y の値や未知を予測することを主な目的とする研究です。たとえば、Table 4.1 で推定されたモデルを用いて、ある個人の属性情報（年齢や性別）をもとに、その人の賃金を予測する場合などが該当します。

関係性把握を目指す研究と比較した場合、予測研究の大きな特徴はモデルの中身、すなわち各パラメータの意味や解釈が重視しない点にあります。予測研究では、特定の事例についての具体的な予測値や最終的な予測の精度こそが、意思決定に活用したい重要な情報となります。。

以上の違いを図示すると以下のようになります:

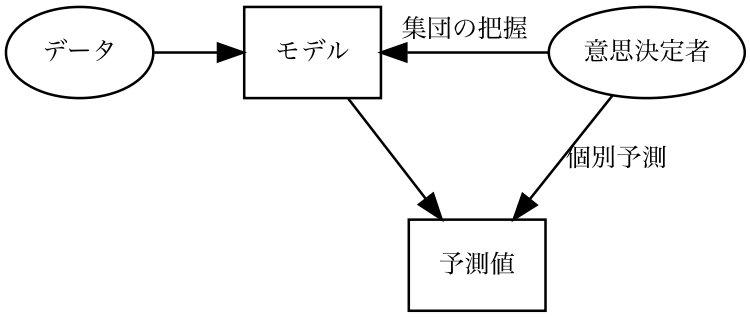

Figure4.2: 意思決定者の視点

推定結果から、集団の特徴を把握し、意思決定に活用したい場合、モデルそのものを理解する必要があります。対して予測値を活用したい場合は、モデルそのものを理解する必要は必ずしもありません。モデルから (PC によって) 計算される予測値、そしてその予測値の精度に関する評価値、さえ理解できれば十分です。例えば、筆者を含めた多くの人は、「日々の天気予報は活用するが、その根拠となる気象モデルは理解していない」のではないでしょうか。

このため、予測研究では、人間が予測モデルの構造を完全に理解できなくても、大きな問題とはされません。むしろ、より高い予測精度を実現するために、複雑なモデルが積極的に用いられる傾向があります。たとえば、以下のような二乗項と交差項 (変数同士の掛け算) を含むモデルが考えられます。

$$\beta_0 + \beta_1 \times gender female + \beta_2 \times age$$
$$+\beta_3 \times age^2 + \beta_4 \times gender female \times age$$

このような複雑なモデルであっても、OLS によって推定することが可能です。

```
library(tidyverse)

data("CPSSW04", package = "AER")

model <- lm(
  earnings ~ gender + age +
    I(age^2) + gender:age,
  CPSSW04)

summary(model)
```

```
Call:
lm(formula = earnings ~ gender + age + I(age^2) + gender:age,
    data = CPSSW04)
```

```
Residuals:
    Min      1Q  Median      3Q     Max
-17.454  -5.848  -1.663   3.776  43.201

Coefficients:
                  Estimate Std. Error t value Pr(>|t|)
(Intercept)      -28.19054   11.51761  -2.448  0.01440 *
genderfemale       7.71998    2.00610   3.848  0.00012 ***
age                2.52954    0.78055   3.241  0.00120 **
I(age^2)          -0.03283    0.01314  -2.498  0.01251 *
genderfemale:age  -0.33826    0.06715  -5.037 4.83e-07 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 8.569 on 7981 degrees of freedom
Multiple R-squared:  0.04336,   Adjusted R-squared:  0.04288
F-statistic: 90.43 on 4 and 7981 DF,  p-value: < 2.2e-16
```

モデルの予測性能の評価値についても、シンプルな線形モデルを推定する限りは、決定係数 `Multiple R-squared` などを近似的な指標として使うことができます。

注意が必要なのは、モデルを「関係性の把握」の用途で用いる際に重視される (論文で必ず報告される) 標準誤差 (`Std. Error`) や p 値 (`Pr(>|t|)`) は、予測において重要な指標ではないという点です。

4.3.1 OLS の注意点

予測分析においても、モデルを複雑化することの弊害は存在します。それは、パラメタの推定精度の悪化に伴う、予測精度の低下です。

限られた事例数を用いて、あまりにも複雑なモデルを推定すると、推定の精度が極端に悪化し、劣悪な予測精度となってしまいます。このような現象は、**過剰適合** (あるいは**過学**

習) と呼ばれ、予測分析における大きな課題となります。

過剰適合を減らし、予測性能を確保するためには、モデルを複雑にしすぎないことが必要です。ただし、特に説明変数が多い場合、研究者がモデルの複雑性を適切にコントロールすることは、事実上不可能です。

またモデルを複雑にすると、通常の決定係数などでは、モデルの予測性能を正しく測定できなくなり、事前のサンプル分割などの対応が必要となります。

近年では、より柔軟にデータを活用する手法が注目されています。代表的なものとして、機械学習分野における教師付き学習[*2]があり、経済学の分野でもその応用が急速に進んでいます。これらの手法は、複雑なモデルであっても予測精度を確保するためのさまざまな工夫が導入されている点が特徴です。

4.4　比較

OLS がよく応用されてきた研究目標の一つに、特定の変数間の関係性を明らかにする比較研究があります。たとえば、賃金（earnings）と学歴（degree）の関係を調べる研究がその例です。

このような課題に対しては、以下のようなシンプルな線形モデルを推定することで、基本的な関係性を把握することができます。

```
estimatr::lm_robust(
  earnings ~ degree,
  CPSSW04)
```

```
                Estimate Std. Error   t value      Pr(>|t|)  CI Lower  CI Upper
(Intercept)    13.809614  0.1020732 135.29131  0.000000e+00 13.609524 14.009705
degreebachelor  6.497478  0.1884088  34.48606 4.554001e-243  6.128148  6.866809
                 DF
(Intercept)    7984
```

[*2] James et al. (2021)

```
degreebachelor 7984
```

この推定結果から、大学卒とそれ以外を比較する、大学卒の方が概ね 6.14 ～ 6.86 ほど平均賃金が高いと考えられます。

4.4.1 調整後の比較

以上のような**単純比較**では、全体の特徴把握の単なる応用であり、比較分析固有の論点は存在しません。OLS を用いる利点は、賃金と学歴の関係について、より詳細な特徴を捉える**調整後の比較**が可能な点にあります。

たとえば、「もし大学卒と非大学卒の間で、性別や年齢の分布に違いがなかった (同じ分布になるように調整した) としたら、賃金格差はどうなるか？」といった疑問に答えることができます。

実際のデータでは、大学卒と非大学卒の間で性別や年齢の分布に差があります。こうした差を統計的に調整したうえで賃金を比較するには、直接の関心ではない説明変数（この場合は `age` や `gender`）について、より柔軟に定式化したモデルを用いることが有効です。

例えば、以下のようなモデルを推定することが考えられます:

$$\underbrace{\beta_D}_{\text{関心}} \times degreebachelor + \beta_0 + \beta_1 \times genderfemale + \beta_2 \times age$$
$$+\beta_3 \times age^2 + \beta_4 \times genderfemale \times age$$

重要な点は、上記の" 長い式" のなかで、研究目標に回答するために用いる情報は β_D だけであるという点です。他の係数は、`age` や `gender` のずれを調整するために導入されており、その係数についての推定結果は関心ではなりません[*3]。

以下はコードで推定できます。

この推定結果から、大学卒の人の平均賃金は、概ね 6.48 ～ 7.20 ほど高いという結果が得られ、単純なモデルよりも格差がやや広がっていることがわかります。

[*3] Nuisance (迷惑/局外/撹乱/補助) parameter と呼ばれます。

Table4.2

```
model <- estimatr::lm_robust(
  earnings ~ degree +
    age + gender +
    I(age^2) + age:gender, # gender と age について交差項と二乗項を導入
  CPSSW04)

confint(model)[2,] # degreebachelor についての信頼区間
```

```
   2.5 %   97.5 %
6.468862 7.193564
```

調整後の比較は、意思決定者がモデルの特徴を理解することで、社会の特徴を把握を目指している、という点で予測よりも、全体の特徴把握に類似しています。

最後に改めて、モデル全体 (すべての β) ではなく、比較の対象となる変数 (上記では degree) の β のみが、社会の把握に活用したい情報であり、信頼区間を表示していることに注意してください。degree 以外の変数について複雑な定式化が許容されるのは、それらは「意思決定者が理解しなくて良い情報である」と割り切っているからです。

4.4.2　OLS の注意点

以上のように、関心外の変数について「人間が理解できないほど複雑なモデル」を設定することは許容されますが、「データから推定できないほど複雑なモデル」は当然避ける必要があります。すなわち予測モデルと同様に、モデルを適切に定式化し、過剰適合を減らす必要があります。

調整後の比較における過剰適合の問題については、予測研究と同様に、機械学習の活用に注目が集まっています。特に Double/Debiased Machine Learning は、機械学習による予測モデルと OLS (より一般にはモーメント法) を組み合わせることで、定式化の柔軟性と統計的推論 (信頼区間の計算など) を両立する手法として、実証研究でも活用されてい

ます。

また OLS を用いた比較には、他のいくつかの問題点も指摘され、それを解消できる手法も開発されてます。例えば、傾向スコアやエントロピーウェイトなどを活用する方法 (Hainmueller 2012) が有名です[*4]。

4.5　因果効果

経済学における OLS の重要な活用事例は、「因果効果の推定」です。ただしこの研究目標は、ここまでの議論と質的に異なることに注意が必要です。

最大の違いは、データや母集団において「因果効果」は変数として観察できない点です。現代的なデータ分析において因果効果は、変数として観察できるものではなく、何らかの理論的な枠組み (思考実験) によって定義される概念であると考えられています。

例えば、`degreebachelor` の信頼区間は 6.49 ～ 7.18 であったとしても、「大学進学が賃金を平均的に増加させる因果的効果を持つ」と結論づけることはできません。その理由は、`degree` 間の賃金格差が、`age` や `gender` 以外の要因によって生じている可能性があるからです。

因果効果の推定についてのデータ分析は、以下のように整理できます。

[*4] OLS が持つ問題点や他の方法を紹介した資料としては、(Chattopadhyay and Zubizarreta 2024)^(https://hdsr.mitpress.mit.edu/pub/1ybwbmlw/release/2) を推奨します。

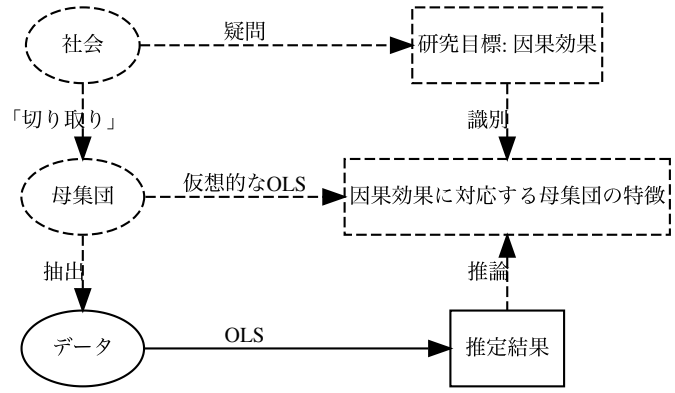
社会
疑問
研究目標: 因果効果
「切り取り」
識別
母集団
仮想的なOLS
因果効果に対応する母集団の特徴
抽出
推論
データ
OLS
推定結果

研究目標は因果効果ですが、それをそのままデータから推定できません。このためまずは、概念である因果効果と理論的に対応する母集団の特徴を特定 (識別) し、それをデータから推定する、という 2 段階のステップが必須となります。

このように、データから得られた推定結果をもとに因果効果をどのように推論するかという問題は、「統計的因果推論」と呼ばれる分野で活発に研究されています[*5]。

4.5.1　OLS の注意点

因果効果の推定と研究目標において、OLS は予測や比較とは決定的に異なる限界があります。それは OLS のみでは、「理想的な方法で抽出されており、無限大の事例数がであっても」、因果効果が推定できないという問題です。

例えば「大学卒と非大学卒の間での平均賃金の差」という比較研究については、ランダムサンプリングかつ無限大の事例数があれば、その問いに正確に回答できます (母平均の差を正確に推定できる)。ところが教育の因果効果を推定する場合は、そのような差が本当に因果効果と一致するのか、識別する必要があります。

言い換えれば、「ランダムサンプリング + 無限大の事例数」という理想的な状況であったとしても推定できるのは、あくまで母集団における観察できる変数分布であり、観察できない概念ではありません。

このため因果推論の推定には、狭義での統計学/機械学習とは別の枠組み[*6]を用いて、概念としての因果効果を母集団上での観察できる変数の分布に結びつける必要があります。そして、この結びつけを識別と呼びます。

対して識別ができれば、OLS は強力な推定手法となります。例えば「介入の条件つきランダム化 + SUTVA」という (識別のための) 仮定が成り立つのであれば、調整後の比較で紹介した OLS の活用方法をそのまま用いて、平均因果効果を推定できます。

[*5] Chernozhukov et al. (2025), Wager (2024) , Ding (2024) (ドラフト版: Ding (2023))
[*6] Cinelli et al. (2025); Wang, Richardson, and Robins (2025)

4.6　まとめ

以上では OLS を利用できる具体的な研究目標として、変数の関係性把握、予測、調整後の比較、因果効果、を紹介しました。これら多様な目標を整理する枠組みとしては、以下の 2 軸を用いた表形式が有効です。

分析の対象範囲 \ 研究目標 の性質	観察できる変数	観察できない概念や仕組み
事例群	関係性の簡潔な要約 (Section 4.2) (調整後の) 比較 (Section 4.4)	平均因果効果 (Section 4.5)
個別事例	予測 (Section 4.3)	

縦軸は、対象範囲が個別の事例なのか、それとも事例群なのか、という観点であり、Figure 4.2 で紹介した意思決定者の" 視点" による区分です。

横軸は、対象となるのがデータから観察可能な変数なのか、それとも観察不可能な概念なのか、という視点であり、因果効果の推定と他を区別する決定的な点です。

因果効果は、変数としてデータに含まれておらず、理論的な枠組みを使って定義し、観察できる変数と結びつける必要がある概念です。これと同じ特徴を持つ研究目標としては、「経済学概念とそれを用いた反実仮想実験」があり、構造推定と呼ばれる分野で盛んに研究されています[*7]。

なお右下 (個別事例 × 観察できない概念や仕組み) に対する研究目標は、本ページには含まれていません。このような目標の例としては、「個人因果効果の予測」[*8]などが挙げられます。

[*7] Shapiro (2026) , 上武康亮・遠山祐太・若森直樹・渡辺安虎 (2025) などを参照してください

[*8] Athey and Wager (2019) などを参照してください。

Angrist, Joshua D, and Jörn-Steffen Pischke. 2009. *Mostly Harmless Econometrics: An Empiricist's Companion*. Princeton university press.

Aronow, Peter M, and Benjamin T Miller. 2019. *Foundations of Agnostic Statistics*. Cambridge University Press.

Athey, Susan, and Stefan Wager. 2019. "Estimating Treatment Effects with Causal Forests: An Application." *Observational Studies* 5 (2): 37–51.

Chattopadhyay, Ambarish, and José R. Zubizarreta. 2024. "Causation, Comparison, and Regression." *Harvard Data Science Review* 6 (1).

Chernozhukov, Victor, Christian Hansen, Nathan Kallus, Martin Spindler, and Vasilis Syrgkanis. 2025. *Applied Causal Inference Powered by ML and AI*. https://causalml-book.org/.

Cinelli, Carlos, Avi Feller, Guido Imbens, Edward Kennedy, Sara Magliacane, and Jose Zubizarreta. 2025. "Challenges in Statistics: A Dozen Challenges in Causality and Causal Inference." *arXiv Preprint arXiv:2508.17099*.

Ding, Peng. 2023. "A First Course in Causal Inference." https://arxiv.org/abs/2305.18793.

———. 2024. *A First Course in Causal Inference*. Chapman; Hall/CRC.

Hainmueller, Jens. 2012. "Entropy Balancing for Causal Effects: A Multivariate Reweighting Method to Produce Balanced Samples in Observational Studies." *Political Analysis* 20 (1): 25–46.

Hanley, James A. 2025. "Probabilistic Parameter Estimates That Require Less Small Print." *The American Statistician*, no. just-accepted: 1–11.

James, Gareth, Daniela Witten, Trevor Hastie, and Robert Tibshirani. 2021. *An Introduction to Statistical Learning: With Applications in r*. 2nd ed. Springer Texts in Statistics. Springer. https://www.statlearning.com/.

Shapiro, Jesse M. 2026. *Introduction to Quantitative Economics*. MIT Press.

Wager, Stefan. 2024. *Causal Inference: A Statistical Learning Approach*. Technical report, Stanford University. https://web.stanford.edu/~swager/causal_inf_book.pdf.

Wang, Linbo, Thomas Richardson, and James Robins. 2025. "Causal Inference: A Tale of Three Frameworks." *arXiv Preprint arXiv:2511.21516*.

上武康亮・遠山祐太・若森直樹・渡辺安虎. 2025. **実証ビジネス・エコノミクス**. 日本評

論社.